

Instituto Federal de Educação, Ciência e Tecnologia do Ceará

Engenharia de Computação

Visão Computacional

Prof. Pedro Pedrosa

Relatório N^o 3 - Técnicas de segmentação

Mariana Akeme Ogawa

Fortaleza

Maio de 2019

Sumário

1	Introdução	2
2	Segmentação de imagens	2
2.1	Limiarização por média móvel e Método de Otsu	2
2.2	Crescimento de Regiões	4
2.3	Watershed	4
2.4	Transformada de Hough	5
3	Resultados e discussão	5
3.1	Limiarização	5
3.2	Crescimento de Regiões	6
3.3	Watershed	7
3.4	Transformada de Hough	8
4	Conclusão	9

1 Introdução

Esse trabalho tem como objetivo a implementação e comparação dos processos de segmentação de imagens. Desta forma, será utilizado imagens variadas, e nessas imagens serão aplicados quatro processos de segmentação: Limiarização por média móvel, Crescimento de regiões, Watershed e Transformada de Hough.

O objetivo da segmentação é subdividir uma imagem em regiões ou objetos que a compõem, ou seja, separar a região de interesse da imagem (ROI – Region of Interest), por exemplo, separar o rosto de uma pessoa do fundo da imagem.

Sendo um processo extremamente importante para o Processamento Digital de Imagens (PDI), uma vez que, por exemplo, posso diminuir a quantidade de informação passada para o extrator ou classificador, uma vez que podemos passar apenas a ROI, em vez de passar a imagem toda.

Foram utilizados implementações prontas dos algoritmos de segmentação, da biblioteca scikit - image [1] e OpenCV [2] para o Python, nessa biblioteca temos várias funções de segmentação e imagens padrões para testá-las.

2 Segmentação de imagens

Uma imagem qualquer, denominada i pode ser entendida como uma região R que pode ser particionada em regiões menores $R = R_1, R_2, R_3, \dots R_n$. Podendo ser trabalhadas com a teoria de conjuntos. [3] [4] É possível realizar dois tipos de análises de segmentação: a similaridade e a descontinuidade. Sendo que a primeira trata de uma propriedade qualquer comum, ou seja similar, a um conjunto de pontos. Essa propriedade permite a representação da região a ser segmentada. Já a descontinuidade, é um propriedade que se baseia nas diferenças entre as regiões, especialmente em regiões que definem fronteiras das regiões analisadas. [3]

Existem diversas técnicas para a segmentação de imagens, como apresentado na figura 1 nesse trabalho serão abordadas as seguintes técnicas: Limiarização por média móvel, Crescimento de regiões, Watershed e Transformada de Hough [5].

2.1 Limiarização por média móvel e Método de Otsu

A limiarização tem como objetivo separar o plano principal ou um objeto do plano de fundo em conjuntos que não se sobrepõem. As técnicas de segmentação podem ser divididas em classes:[3]

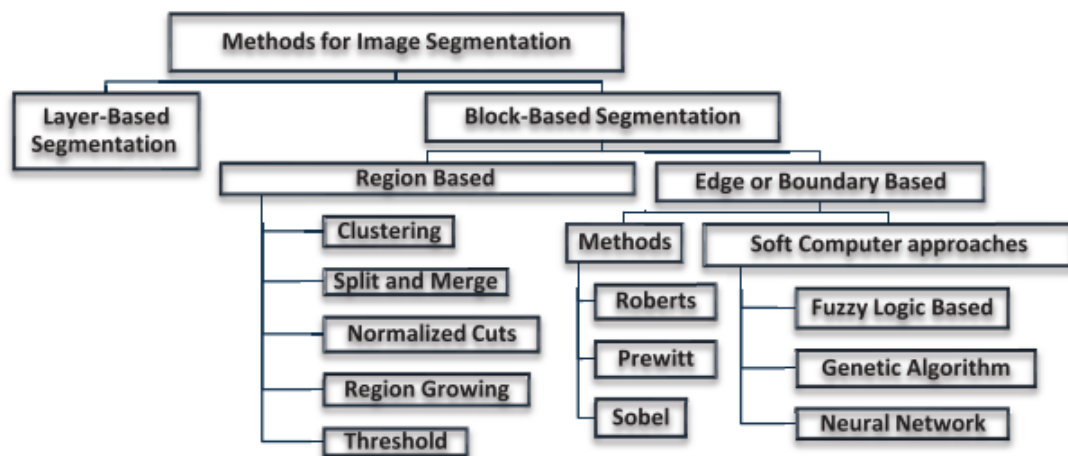


Figura 1: Métodos de segmentação de imagens.

[5]

- Técnicas locais – são baseadas em propriedades locais do pixels e seus vizinhos;
- técnicas globais – segmentam a imagem na base das informações obtidas globalmente, por exemplo, utilizando o histograma da imagem ou as propriedades globais de textura;
- técnicas globais – segmentam a imagem na base das informações obtidas globalmente, por exemplo, utilizando o histograma da imagem ou as propriedades globais de textura;
- técnicas de separação, junção e crescimento utilizam tanto a noção de homogeneidade quanto a de proximidade geométrica para obter bons resultados de segmentação.

Assim, a limiarização para definir as regiões de uma imagem I a partir de propriedade comum aos pixels que formam essas regiões, ela utiliza a intensidade, relacionamento dos pixels e um limiar para representar as diferentes regiões. [3]

Existem diversos métodos para encontrar o limiar: utilizando um valor fixo, a média móvel ou adaptativa. Na qual o limiar T é aplicado de acordo com uma propriedade que leva em conta regiões (janelas) da imagem e o relacionamento dos pixels com sua vizinhança, utilizando por exemplo: variância, desvio padrão, média. Temos também, método de Otsu(1979), que trata de limiarização global ótima, entre outros. [3]

O método de Otsu (1979) modela o problema de limiarização pode ser como um problema estatístico, que tem os seguintes objetivos :[3]

- Minimizar o erro médio na distribuição de pixels para dois ou mais grupos (classes de pixels).
- Encontrar a solução para pode ser possível utilizando dois parâmetros:
 - Função de Densidade de Probabilidade dos níveis de cada classe.
 - Probabilidade de que uma classe ocorra em uma região da imagem.
- Assumir que a as duas ou mais classes apresentam distribuição com comportamento normal.

Esse método é dito ótimo pois baseia-se em nos processos de otimização,ou seja, seja encontrar um valor que maximize a variância entre duas ou mais classes.[3]

2.2 Crescimento de Regiões

O Crescimento de Regiões é uma técnica de segmentação do grupo que se baseia em similaridade. Essa técnica é baseada no agrupamento de pixels em regiões cada vez maiores esse agrupamento ocorre utilizando um critério de crescimento, pré- estabelecidos.[3] [4]

Esse crescimento tem o seguinte princípio: inicialmente iniciamos um conjunto de pontos, chamados de semente(s), esses pontos podem ser definidos de forma manual ou automaticamente. Após, os pixels “candidatos” são agrupados aos pixels sementes utilizando algum critério de similaridade ou alguma propriedade em comum, o chamado critério de crescimento. O pixel “candidato” é adicionado a região, caso ele não pertença nem tenha sido designado para outra região e se ele for vizinho a esta região, por exemplo, conectado ao um pixel pertencente a região. Essa nova região criada pela adição desse pixel deve continuar uniforme. [3]

Em imagens monocromáticas utiliza-se a intensidade dos pixels associada a uma propriedade espacial.[3]

2.3 Watershed

É uma técnica de segmentação que foi inspirada no conceito da geografia que define o comportamento da inundação da região mínima entre contornos máximos adjacentes. Sendo um dos métodos que se baseiam no conceito de região, formando fronteiras conexas. [3]

Ele tem como objetivo encontrar as linhas divisórias entre as regiões. Para isso, realiza uma análise da imagem, em um domínio de três dimensões: duas coordenadas e a terceira uma intensidade.[3]

2.4 Transformada de Hough

É uma técnica baseada em descontinuidades, ou seja, mudanças locais com mudanças abruptas de intensidade. Para tanto essa técnica deve ser utilizada em imagens já binarizadas, sendo útil para a detecção de linhas, círculos e elipses na imagem, um dos grandes atrativos dessa técnica é o seu baixo conjunto computacional. [3]

Para realizar essa transformada tem dois algoritmos bases: o primeiro: baseia-se na ideia de encontrar todas as retas para cada dois pares de pontos, após encontrar os subconjuntos de pontos que estejam próximo da reta desejado, tendo o custo $O(n^3)$. A segunda técnica, parte da representação explícita da forma, ou seja da Equação, para limitar o conjunto de parâmetros das retas que representam pares de pontos. Em seguida, os parâmetros que se repetirem representam a colinearidade entre o par de pontos. Custo $O(n^2)$. [3]

3 Resultados e discussão

As técnicas de segmentação apresentadas tem características diferentes e por causa disso servem para segmentar diferentes tipos de regiões. Dessa forma, ao tentar segmentar algumas imagens com determinadas técnicas, temos um resultado não satisfatório, apresentando ou uma imagem totalmente branca (os pixels foram para o maior valor), ou totalmente preta (os pixels foram para o valor zero).

Assim, caso tenha alguma informação a priori da imagem a ser segmentada pode ser avaliado previamente qual o melhor algoritmo de segmentação para fazê-la. Caso, não exista essa informação deve se aplicar diversas técnicas e observar a que apresenta de melhor forma a ROI.

As técnicas foram implementadas a partir de funções das bibliotecas OpenCV [2] e Scikit-imagens [1], sendo que várias dela temos apenas alguns parâmetros de ajustes.

3.1 Limiarização

As técnicas de limiarização são utilizada principalmente para a separação de objetos dos plano de fundo. Sendo determinado o limiar a partir do seu histograma, a figura 2 apresenta tanto a imagem original, quanto o resultado utilizando um limiar global e a resposta, vemos que no caso apresentado o limiar adaptativo resalta o texto que é nossa ROI.

A figura 3 apresenta a aplicação do limiar ótimo de Otsu, onde também é apresentado o histograma da imagem com uma reta marcando o ponto ótimo do histograma, vale observar que nesse caso

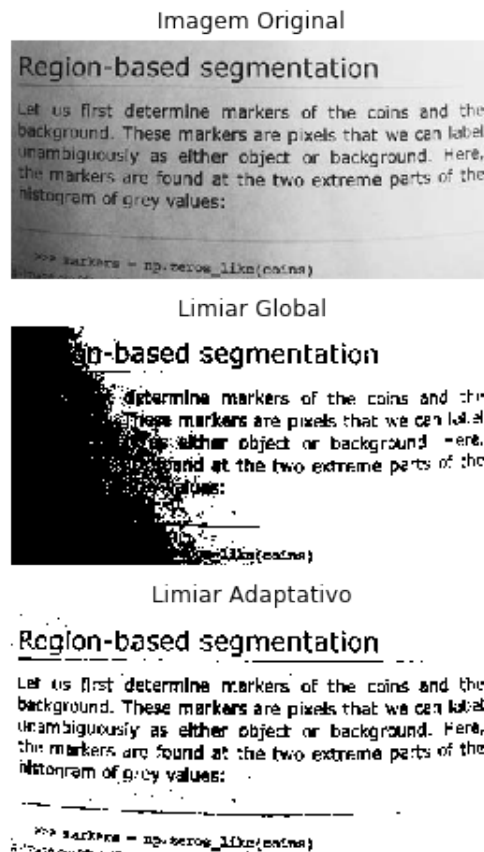


Figura 2: Limiarização Adaptativa.

3.2 Crescimento de Regiões

O algoritmo de crescimento de regiões deve ter algum critério de parada, seja o tempo ou então a quantidade de iterações. O critério utilizado no algoritmo desse trabalho foi o temporal, podendo ser interrompido também manualmente pelo usuário.

A imagem para ser aplicado o processo de segmentação de crescimento de regiões deve ser preprocessada, como na maioria dos processos de digital de imagens a figura pode ser trabalhada em escala de cinze. A figura 4(a) apresenta a imagem após uma mudança a escala de cinza,

Vale ressaltar que o algoritmo implementado mostra o crescimento ao longo do tempo. A figura 4(b) temos a imagem segmentada. A região destacada equivale ao algoritmo A da imagem original, o crescimento iniciou-se internamente a essa região e como ocorre uma mudança abrupta com o fundo da imagem, foi a parte segmentada.

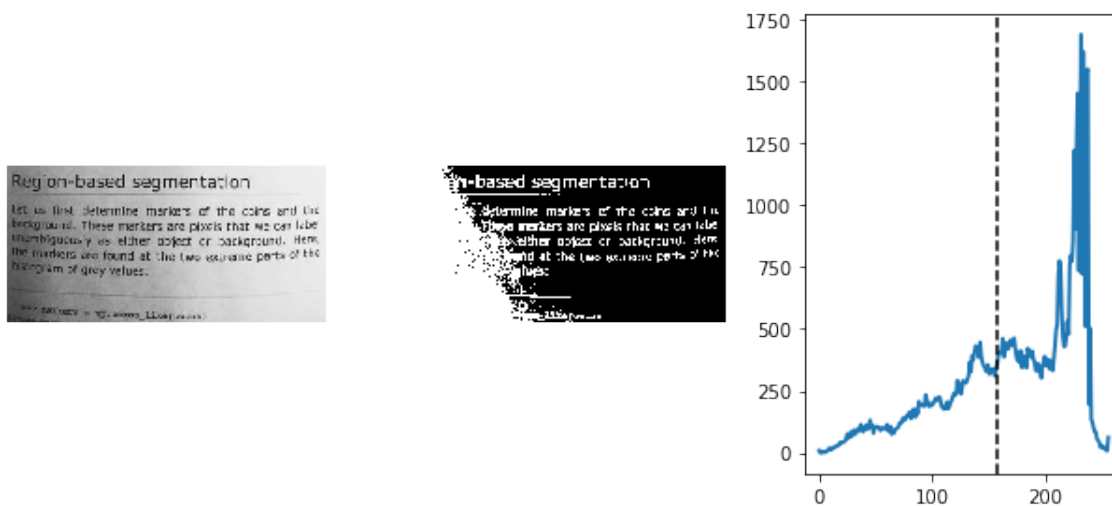


Figura 3: Limiarização Técnica de Otsu.



Figura 4: Imagem original e após ser segmentada pela técnica de crescimento de regiões.

3.3 Watershed

Esse algoritmo tem como finalidade achar regiões conexas, a região de interesse deve está contida dentro de uma dessas regiões na fig. 5(a) temos a imagem que desejamos segmentar, a região de interesse seriam as moedas separando-as do fundo da imagem. Serão apresentadas duas implementações desse algoritmo a primeira, na fig. 5(b), a implementação utilizando das funções da OpenCV, além disso foram realizados tratamentos intermediários.

Já a implementação utilizando as funções da biblioteca scikit-image, é apresentada na fig. 6, apresentando ao final temos a região de interesse em preto, separada do resto da imagem que está colorido.

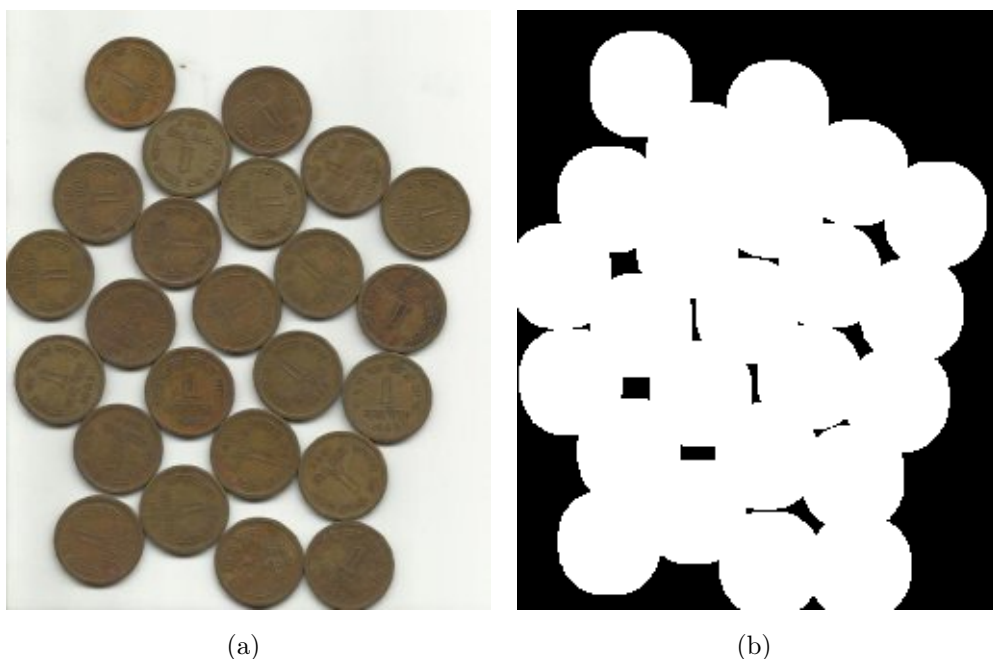


Figura 5: Imagem original e após ser segmentada pela técnica de watershed.




Figura 6: WaterShed utilizando a biblioteca Scikit-image

3.4 Transformada de Hough

Esse tipo de segmentação é o ideal para encontrar linhas dentro da imagem, pode-se usar variações na função e encontrar regiões circulares. Desta, forma utilizando a transformada padrão, que encontra regiões delimitadas por linhas, não seria possível segmentar a imagem original utilizada para aplicação do watershed.

Na fig. 7(a) temos a figura original a ser segmentada, pelas características da mesma vemos que o crescimento de regiões de watershed não trariam resultados satisfatórios e não é possível utilizar a limiarização, uma vez que a imagem já está com dois valores.

Assim, desejamos achar as “linhas” de interesse que constituem a imagem, a fig. 7(b) apresenta as mesma em vermelho.




Figura 7: Imagem original e após ser segmentada pela técnica de Transformada de Hough.

4 Conclusão

O processo de segmentação pode ser considerado um procedimento intermediário nas análises em visão computacional. Desta forma, antes de segmentar a imagem, pode-se fazer um pré-processamento das imagens, podendo ser utilizados filtros e até diversas técnicas de segmentação na mesma imagem.

Para diminuir o esforço computacional para encontrar a região de interesse, podemos fazer ajustes antes mesmo de coletar a imagem: por exemplo, se estamos interessados em localizar as moedas em cima de uma mesa, não é necessário tirar uma foto da sala inteira. Assim, ao colocar a imagem com foco na região de interesse diminui o processamento e diminui a possibilidade de erros, pois pode ter algum outro objeto semelhante aquele desejado a ser segmentado.

As quatro técnicas apresentadas no trabalho, tem funções de segmentação bastante diferentes. Dessa forma, caso tenhamos algum conhecimento prévio, podemos escolher uma técnica mais adequada a encontrar a região desejada na imagem e nada impede que seja escolhido apenas uma, por exemplo, podemos aplicar, no caso da imagens das moedas, uma limiarização e após isso um watershed.

Além das técnicas abordadas, temos diversas outras técnicas de segmentação com outras funções, tais como: o convex Hull, outros tipo de limiarização, algoritmos para detecção de bordas. Entre esses algoritmos de detecção de borda, temos os filtros de Sobel e Prewitt, que também podem ser considerados um processo de filtragem.

Assim, em um projeto de PDI, todas as etapas deve ser levadas em consideração e não existem uma técnica que consiga obter boa resposta em todos os caso. Uma vez, que podemos fazer uma filtragem junto com o processo de segmentação, e caso usemos o processo de segmentação errado não iremos ter informações úteis.

Referências

- [1] scikit-learn: machine learning in python — scikit-learn 0.21.1 documentation, how-published = <https://scikit-learn.org/stable/modules/classes.html>, note = Accessed: 2019-03-20.
- [2] Opencv library. <https://opencv.org/>. Accessed: 2019-03-12.
- [3] R.C. Gonzalez and R.E. Woods. *Processamento Digital De Imagens*. ADDISON WESLEY BRA, 2008.
- [4] C. Solomon and T. Breckon. *Fundamentals of Digital Image Processing: A Practical Approach with Examples in Matlab*. Wiley, 2011.
- [5] Nida M. Zaitoun and Musbah J. Aqel. Survey on Image Segmentation Techniques. *Procedia Computer Science*, 65(Iccmit):797–806, 2015.